

Logistic Regression

逻辑回归算法核心思想

先用线性拟合，然后量化线性拟合的预测结果，即将连续值量化为离散值。(使用线性回归+阈值解决分类问题)。逻辑回归将连续值映射到(0,1)，采用的是Sigmoid函数(也称为Logistic函数、S函数)。

Sigmoid函数与决策边界

Sigmoid函数: $S(x) = \frac{1}{1+e^{-x}}$

决策边界: 分类器对样本进行区分的边界，包括线性决策边界和非线性决策边界。

线性决策边界

e.g. 用函数 g 表示Sigmoid函数，逻辑回归的输出结果由假设函数

$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$ 得到，这里 $\theta_0 + \theta_1 x_1 + \theta_2 x_2$ 就是线性边界。

非线性决策边界

e.g. 用函数 g 表示Sigmoid函数，逻辑回归的输出结果由假设函数

$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_2^2)$ 得到，这里 $\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_2^2$ 就是非线性边界。(无法用直线/超平面把不同类别的样本分开)

梯度下降与优化

损失函数和成本成本函数

1. 损失函数/目标函数/代价函数: 量化模型好坏的函数，损失函数(Loss function)是在单个训练样本上的表现。在逻辑回归模型中，损失函数采用对数损失函数(二元交叉熵损失):

$$Cost(h_{\theta}(x), y) = -[y \cdot \log(h_{\theta}(x)) + (1 - y) \cdot \log(1 - h_{\theta}(x))] = \begin{cases} -\log(1 - h_{\theta}(x)) & y = 0 \\ -\log(h_{\theta}(x)) & y = 1 \end{cases}$$

2. 成本函数(Cost function)是在全体训练样本上的表现，也就是对损失函数(Cost function)的求和。公式:

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m [y^{(i)} \log(h_{\theta}(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)}))]$$

梯度下降(Gradient Descent)

利用梯度下降，要求出最优参数 θ ，则需要最小化 $J(\theta)$ 同时更新参数 $\theta_j := \theta_j - \alpha \frac{\partial J(\theta)}{\partial \theta_j}$ 。在公式中 α 代表学习率，直观意义是在函数向极小值方向前进时的步长。(太大会导致错过极小值，太小会导致迭代次数过多)

对Sigmoid函数和 $J(\theta)$ 函数求导可得更新公式： $\theta_j := \theta_j - \alpha \frac{1}{m} \sum_i^m (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)}$

正则化与防止过拟合

添加正则化项可以防止过拟合，故在成本函数(Cost function)中添加正则化项后为： $J(\theta) = -\frac{1}{m} \sum_{i=1}^m [y^{(i)} \log(h_\theta(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_\theta(x^{(i)}))] + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$ ， λ 表示正则化系数，即为惩罚程度： λ 越大，为使 $J(\theta)$ 的值小，参数 θ 的绝对值就越小。