



# SVM

## 分类




线性可分支持向量机

linear support vector machine  
in linearly separable case  
亦称作硬间隔支持向量机



线性支持向量机

linear support vector machine  
又叫软间隔支持向量机



非线性支持向量机

non-linear  
support vector machine

搜索 | 微信 ShowMeAI 研究中心

1. 线性可分支持向量机：训练数据线性可分的情况下，通过硬间隔最大化(hard margin maximization)学习一个线性的分类器
2. 线性支持向量机：训练数据近似线性可分的情况下，通过软间隔最大化(soft margin maximization)学习一个线性的分类器
3. 非线性支持向量机：训练数据线性不可分的情况下，通过使用核技巧(kernel trick)以及软间隔最大化，学习非线性分类器

核函数(kernel function): 表示将输入从输入空间映射到特征空间得到的特征向量之间的内积

核技巧(kernel trick): 使用核函数学习非线性支持向量机，等价于隐式地在高维的特征空间中学习线性支持向量机

SVM是一个二分类模型


## 最大间隔分类器



决策边界有无数个，但是要找到与两侧最近的数据点有最大距离的决策边界，这样的边界有最大的容错性。


## SVM详解

### 线性可分SVM与硬间隔最大化



边界  $f(x) = \mathbf{w} \cdot \mathbf{x} + b$ ，其中  $\mathbf{w}$  与  $\mathbf{x}$  都是向量，公式等价于

$$f(x) = w_1x_1 + \dots + w_nx_n + b$$



红色和蓝色的线是支持向量(support vector)所在的面，红色和蓝色线之间的间隙就是要最大化的分类间的间隙M(Margin Width)， $M = \frac{2}{\|w\|}$

定义：特征空间训练数据集  $T = (x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)$ ，其中  $x_i \in R$ ， $y_i \in \{+1, -1\}$ 。 $x_i$ 代表第*i*个特征向量； $y_i$ 是类标记，+1为正例，-1为负例

## 几何间隔

超平面  $w \cdot x + b = 0$ ，超平面关于样本点  $(x_i, y_i)$  的几何间隔为  $\gamma_i = y_i \left( \frac{w}{\|w\|} \cdot x_i + \frac{b}{\|w\|} \right)$ ，超平面关于所有样本点的几何间隔的最小值为  $\gamma = \min_{i=1,2,\dots,N} \gamma_i$  (即为 支持向量到超平面的距离 )

1. SVM模型的求解最大分割超平面问题等价于： $\max_{w,b} \gamma$  s.t.  $y_i \left( \frac{w}{\|w\|} \cdot x_i + \frac{b}{\|w\|} \right) \geq \gamma$ ，s.t.代表subject to，即为约束条件
2. 将约束条件两边同时除以 $\gamma$ ： $y_i \left( \frac{w}{\|w\|\gamma} \cdot x_i + \frac{b}{\|w\|\gamma} \right) \geq 1$
3. 令  $w = \frac{w}{\|w\|\gamma}$ ， $b = \frac{b}{\|w\|\gamma}$ ： $y_i (w \cdot x_i + b) \geq 1$
4. 最大化 $\gamma$ 等价于最大化  $\frac{1}{\|w\|}$ ，等价于最小化  $\frac{1}{2} \|w\|^2$ 。因此SVM求解最大分割超平面问题化成： $\min_{w,b} \frac{1}{2} \|w\|^2$  s.t.  $y_i (w \cdot x_i + b) \geq 1$

## 对偶算法

将求解线性可分支持向量机的最优化问题转换成 对偶问题(dual problem) 来求解

1. 构建拉格朗日函数(Lagrange function):

$$L(w, b, \alpha) = \frac{1}{2}w^T w + \sum_{i=1}^N \alpha_i (1 - y_i(w^T x_i + b)) = \frac{1}{2}w^T w - \sum_{i=1}^N \alpha_i y_i (w^T x_i + b) + \sum_{i=1}^N \alpha_i$$

，其中 $\alpha_i \geq 0$ 是拉格朗日乘子。根据拉格朗日对偶性，原始问题等价于极大极小问题 $\max_{\alpha} \min_{w, b} L(w, b, \alpha)$

2. 求 $L(w, b, \alpha)$ 对 $w, b$ 的极小值：

$$\frac{\partial L}{\partial w} = 0 \rightarrow w = \sum_{i=1}^N \alpha_i y_i x_i, \quad \frac{\partial L}{\partial b} = 0 \rightarrow \sum_{i=1}^N \alpha_i y_i = 0$$

代入到 $L(w, b, \alpha)$ 可得：

$$\min_{w, b} L(w, b, \alpha) = \frac{1}{2} \left( \sum_{i=1}^N \alpha_i y_i x_i \right)^T \sum_{i=1}^N \alpha_i y_i x_i - \sum_{i=1}^N \alpha_i y_i \left( \left( \sum_{i=1}^N \alpha_i y_i x_i \right)^T x_i + b \right) + \sum_{i=1}^N \alpha_i$$

$$\text{化简为} \min_{w, b} L(w, b, \alpha) = -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i y_i \alpha_j y_j x_i^T x_j + \sum_{i=1}^N \alpha_i$$

3. 求 $\min_{w, b} L(w, b, \alpha)$ 对 $\alpha$ 的极大值：

$$\max_{\alpha} \left( -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i y_i \alpha_j y_j x_i^T x_j + \sum_{i=1}^N \alpha_i \right) \quad s.t. \quad \sum_{i=1}^N \alpha_i y_i = 0$$

$$\text{等价于} \min_{\alpha} \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i y_i \alpha_j y_j x_i^T x_j - \sum_{i=1}^N \alpha_i \quad s.t. \quad \sum_{i=1}^N \alpha_i y_i = 0$$

4. 假设对偶最优化问题对 $\alpha$ 的解为 $\alpha^*$ ：

$$\text{求得} w^* = \sum_{i=1}^N \alpha_i^* y_i x_i$$

$$\text{根据KKT条件：} \begin{cases} \text{乘子非负：} \alpha_i \geq 0 \\ \text{约束条件：} y_i(w \cdot x_i + b) \geq 1 \\ \text{互补条件：} \alpha_i(y_i(x_i^T w + b) - 1) = 0 \end{cases}$$

至少存在一个 $j$ 使得 $y_j(x_j^T w^* + b^*) - 1 = 0$ ，因此 $b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i x_j^T x_i$  (注意 $y_j^2 = 1$ )

5. 分离超平面可以写成：

$$\sum_{i=1}^N \alpha_i^* y_i (x \cdot x_i) + b^* = 0$$


决策函数只依赖于输入 $x$ 和训练样本输入 $x_i$ 的内积

6. 分类决策函数可以写成：

$$f(x) = \text{sign}\left(\sum_{i=1}^N \alpha_i^* y_i (x \cdot x_i) + b^*\right)$$

## 线性SVM与软间隔最大化

### 方案1




#### 方案1

用曲线去将其完全分开  
即非线性的决策边界

搜索 | 微信 ShowMeAI 研究中心

用曲线将其完全分开(非线性决策边界)

### 方案2



#### 方案2

使用直线

不追求完全可分  
适当包容一些分错的情况

搜索 | 微信 ShowMeAI 研究中心

使用直线，不追求完全可分，但加入惩罚函数(分错点到正确未知的距离)

图中绿色的线代表分错点到其相应的决策面距离

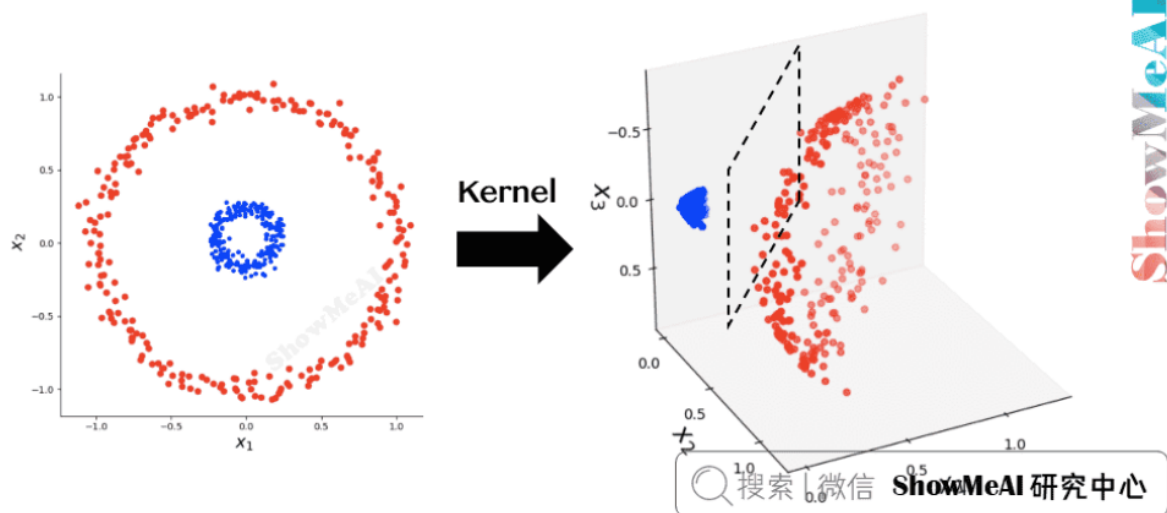
则问题可化为： $\min \frac{1}{2} \|w\|^2 + C \sum_{i=1}^R \epsilon_i$  s.t.  $y_i(w^T x_i + b) \geq 1 - \epsilon_i$ ，其中 $R$ 为全部点的数目， $C$ 是由用户指定的系数(表示对分错点加入多少的惩罚)，当 $x_i$ 在正确一边时 $\epsilon$ 为0

同样可以求解一个拉格朗日对偶问题，得到原问题的对偶问题的表达式：

$$\max_{\alpha} \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i,j=1}^N \alpha_i \alpha_j y_i y_j x_i^T x_j \text{ s.t. } 0 \leq \alpha_i \leq C, \sum_{i=1}^N \alpha_i y_i = 0$$

## 非线性SVM与核函数

无法近似可分的情况下，可以将样本从原始空间映射到更高维的特征空间，使得样本在这个特征空间内线性可分，然后用SVM进行求解。



$$\text{对偶问题: } \max_{\alpha} \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i,j=1}^N \alpha_i \alpha_j y_i y_j x_i^T x_j \text{ s.t. } 0 \leq \alpha_i \leq C, \sum_{i=1}^N \alpha_i y_i = 0$$

令 $x_i^T x_j = \kappa(x_i, x_j)$ ，这个式子作用就是将线性的空间映射到高维的空间。

常见的有多项式核 $\kappa(x_i, x_j) = (x_i \cdot x_j + 1)^d$ ，高斯核 $\kappa(x_i, x_j) = e^{-\frac{(x_i - x_j)^2}{2\sigma^2}}$